AI-судья по правилам D&D 5e с учётом версий и домашних правил

Годовой проект · RAG-система / дообучение LLM под домен · уровень PRO · ноябрь 2026

1. Предметная область

Правила настольной ролевой игры Dungeons & Dragons 5-й редакции в двух официальных версиях: 2014 года (SRD 5.1) и обновлённой 2024 года (SRD 5.2.1). Обе версии опубликованы издателем под открытой лицензией CC BY 4.0, поэтому корпус можно легально собирать, обрабатывать и выкладывать.

- **Две версии одних правил.** Одно и то же заклинание работает по-разному: «Контрзаклинание» в 2014 автоматически отменяет заклинания до 3-го уровня, а в 2024 цель делает спасбросок Телосложения.
- **Мультихоп.** Типичный вопрос связывает 2–4 правила: заклинание, состояние, действие, особенность класса.
- **Структура.** Правила состоят из сущностей с явными связями: это естественный граф.
- **Модель «помнит» D&D из предобучения** и смешивает версии, выдумывает правила, подтягивает домашние правила с форумов. Это готовый и измеримый источник галлюцинаций.

2. Идея и проблема

Проблема. Игрокам и мастерам нужны точные ответы по правилам на сотнях страниц. Поиск по ключевым словам выдаёт куски текста, но не отвечает на вопрос, где нужно связать несколько правил. LLM без контекста отвечает уверенно, но галлюцинирует.

Решение. Система вопрос-ответ, которая отвечает со ссылками на разделы правил и с указанием версии. В расширенной части мастер загружает документ с домашними правилами (хоумрулами) своего стола, и система отвечает по иерархии: **хоумрулы стола → правила выбранной версии**, даже если модель «знает» официальный вариант.

Пример. Стол играет по правилам 2014 года с хоумрулом «зелье лечения на себя — бонусным действием». Вопрос «Могу ли я выпить зелье и атаковать в этот ход?» требует учесть оба уровня.

ЧАСТЬ A. Базовое решение — всё, что требует ТЗ

Базовая часть закрывает все задачи и критерии приёмки ТЗ, включая перечисленные в нём усложнения (RAG против fine-tuning, борьба с галлюцинациями, adversarial-тест). Её достаточно для сдачи проекта.



3. Пайплайн базового решения

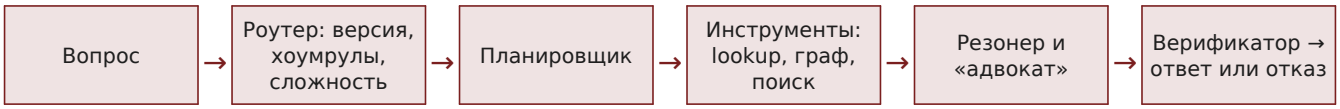
Этап	Что делаем	Результат
A1. Сбор корпуса	Скачиваем SRD 5.1 (Markdown) и SRD 5.2.1 (PDF), данные Open5e для обеих версий, дамп RPG Stack Exchange.	data/raw/, скрипты загрузки
A2. Подготовка	PDF → Markdown; разбиение по структуре правил (раздел → правило, отдельный чанк на заклинание и состояние); метаданные: версия, тип сущности, раздел.	Чанки обеих версий, статистика корпуса
A3. Эмбеддинги и индекс	Мультиязычные эмбеддинги (вопросы на русском, корпус на английском), индекс в Qdrant с фильтром по версии.	Проиндексированный корпус
A4. Retrieval + генерация	Гибридный поиск (dense + sparse) → реранкер → генерация open-source LLM 7–8B с обязательными ссылками на разделы SRD.	Работающий RAG-пайплайн
A5. Тестсет с эталонами	300–500 вопросов: шаблонные по Open5e, отфильтрованные со Stack Exchange, на различия версий, неотвечаемые (контент вне SRD), adversarial.	Тестсет с эталонами и категориями
A6. Оценка	RAGAS (faithfulness, answer relevancy, context precision/recall), human eval на 100–150 ответах, latency p50/p95. Бейзлайн: LLM без контекста.	Таблица метрик

Этап	Что делаем	Результат
А7. RAG против LoRA	LoRA той же базовой модели на QA-парах по SRD, сравнение с RAG на том же тестсете. Сущности тестсета не попадают в обучение.	Сравнительная таблица
А8. Галлюцинации и adversarial	Отдельный набор: выдуманные заклинания, ложные посылки, смешение версий. Классификация ошибок (не нашёл, неверно применил, смешал версии, выдумал, не отказался) и мера против каждого типа: реранкер, порог отказа, фильтр версии, промпт с цитированием.	Отчёт по 30–50 неудачным ответам

Критерии приёмки (порог согласовать с руководителем): корпус собран и проиндексирован; faithfulness ≥ 0.85 и точность ≥ 70% на тестсете; корректный отказ на ≥ 80% неотвечаемых вопросов; задокументированы неудачные ответы и меры их снижения.

ЧАСТЬ Б. Наши усложнения поверх базы

Главная линия: система должна следовать тексту (версии и хоумрулам), а не памяти модели. Каждое усложнение добавляется отдельно, чтобы его вклад был виден в абляции.



Усложнение	Суть
Б1. Домашние правила	Генератор хоумрулов по шаблонам (меняет число, тип действия, добавляет исключение) + 10–20 популярных хоумрулов. Слой «переопределено» поверх официальных правил; эталон известен по построению.
Б2. Граф правил с версиями	Узлы: заклинания, состояния, действия, классы, монстры, типы урона. Рёбра: «накладывает», «запрещает реакции», «требует концентрации», «заменено на» (2014 → 2024), «переопределено» (хоумрул). Подсветка пути ответа на демо.
Б3. Агентный граф	LangGraph: роутер → планировщик → инструменты (оформлены как MCP-серверы) → резонер и агент-«адвокат», ищущий исключения → верификатор. Простые вопросы идут быстрым путём.
Б4. Верификатор утверждений	Ответ разбивается на атомарные утверждения, каждое проверяется (NLI) против цитаты и слоя; без опоры — дозапрос или честный отказ.
Б5. RAFT	Дообучение модели работать с контекстом и игнорировать отвлекающие фрагменты; сравнение RAG, LoRA, RAFT и RAG + RAFT.
Б6. Эксперименты	Version leak rate; следование хоумрулам; тест обновления знаний (LoRA обучена на 2014 → переход на 2024); тест с подменённым контекстом; качество по числу хопов; Парето качество/latency для роутера.
Б7. Калибровка судьи	Согласие LLM-судьи с ручной разметкой (каппа Коэна), судья — другая модель.
Б8. Опционально	Pathfinder 2e (открытая лицензия ORC) как второй корпус; FIREBALL — вопросы с состоянием персонажей из реальных игровых сессий.

4. Источники данных

Данные	Где брать	Формат	Лицензия	Роль
Правила 2014	SRD 5.1 в Markdown: github.com/oznogon/cc-srd	Markdown	CC BY 4.0	Корпус
Правила 2024	SRD 5.2.1: dndbeyond.com/srd	PDF	CC BY 4.0	Корпус
Различия версий	«Converting to SRD 5.2.1», там же	PDF	Справочно	Вопросы на версии, рёбра графа
Сущности	Open5e API (srd-2014, srd-2024): github.com/open5e/open5e-api	JSON	CC BY 4.0	Граф, lookup, шаблонные вопросы
Сверка 2014	github.com/5e-bits/5e-database	JSON	CC BY 4.0 / MIT	Запасной источник
Вопросы людей	Дамп Stack Exchange 2025-12-31 (archive.org), файл rpg.stackexchange.com.7z; теги dnd-5e-2014, dnd-5e-2024	XML	CC BY-SA	Тестсет с эталонами
Хоумрулы	Собственный генератор + вручную записанные	Markdown	Свои	Слой хоумрулов (часть Б)

5. Стек

Слой	Инструмент	Слой	Инструмент
Окружение	Python 3.11+, uv, Docker Compose	LLM	Qwen3-8B или актуальная модель того же класса
Парсинг PDF	Docling или Marker	Инференс	vLLM (Ollama для отладки)
Эмбеддинги	BGE-M3 (dense + sparse, мультиязычная)	Агенты (Б)	LangGraph, инструменты как MCP-серверы
Реранкер	bge-reranker-v2-m3	Верификатор (Б)	NLI-модель (DeBERTa-v3 MNLI) или LLM
Vector store	Qdrant (фильтры по версии и слою)	Дообучение	PEFT + TRL, QLoRA (bitsandbytes)
Граф (Б)	Neo4j Community / NetworkX	Оценка	RAGAS, LLM-судья, scikit-learn
Трекинг	MLflow или W&B; трассы — Langfuse	Демо	Streamlit, визуализация графа — pyvis

Железо: одна GPU 24 ГБ (RTX 3090/4090) или Colab/Kaggle для дообучения; при нехватке — модель 3–4B.

6. Метрики и тестсет

Метрика	Что показывает	Часть
RAGAS: faithfulness, answer relevancy	Достоверность и релевантность ответа	А
RAGAS: context precision / recall	Качество retrieval	А
Точность против эталона (LLM-судья + human eval)	Правильность ответа	А
Latency p50 / p95, токены на ответ	Скорость и стоимость	А
Доля корректных и ложных отказов	Поведение на неотвечаемых вопросах	А
Доля ответов, сбитых adversarial-вопросом	Устойчивость	А
Version leak rate	Смешение правил 2014 и 2024	Б
House-rule compliance	Следует ли система хоумрулу, а не памяти	Б
Каппа Коэна судьи с людьми	Можно ли доверять автоматической оценке	Б

Состав тестсета (500 вопросов к финалу): простые 25%, мультихоп 25%, различия версий 15%, хоумрулы 15% (часть Б), неотвечаемые 10%, adversarial 10%.

7. Ручная разметка

Большая часть эталонов получается автоматически: шаблонные вопросы по Open5e, пути по графу, вопросы по сгенерированным хоумрулам, неотвечаемые и adversarial. Вручную — около 15–25 часов за год: проверка 100–150 вопросов со Stack Exchange (черновик эталона пишет LLM), 50–75 вопросов на версии, выборочная проверка хоумрулов, human eval 100–150 ответов. Ускорение: две разные LLM пишут эталон, вручную проверяются только расхождения.

8. План по срокам

Период	Работа	Контрольная точка
Ноябрь	А1–А3: сбор, парсинг, индекс	Корпус проиндексирован
Декабрь	А4–А6: RAG, тестсет v1, RAGAS, бейзлайн	MVP: требования ТЗ закрыты
Январь–февраль	А7–А8; Б1–Б4: хоумрулы, граф, агенты, верификатор	Агентная система, тестсет v2
Март–апрель	Б5–Б6: RAFT, эксперименты	Таблица сравнения вариантов
Май–июнь	Б7, human eval, разбор провалов, демо, отчёт	Защита

9. Риски

- **Мало вопросов Stack Exchange покрыто SRD** (многие про платные книги) → добираем шаблонными вопросами.
- **Корпус средний по объёму** → аргумент за RAG: точность, версии и хоумрулы; при необходимости Pathfinder 2e.
- **Утечка тестсета в обучение** → разделение выборок по сущностям и явная проверка пересечений.
- **Нейросеть-ассистент в разработке путает версии** → эталоны и разбор правил только с проверкой по тексту SRD.